표본추출법 비교 분석 리포트

seaborn tips 데이터셋 기반

문제 1: tip 변수의 분포, 평균과 분산 설명

문제 2: 3가지 표본추출방법의 평균/분산 비교 및 적합성 토론

앱프로그래밍(1) 과목 | 통계학 기반 머신러닝

1. tip 변수의 분포, 평균과 분산

1-1. 데이터 개요

seaborn의 tips 데이터셋은 레스토랑 고객 244명의 식사 기록이다. tip 변수는 고객이 남긴 팁 금액($)을 나타낸다.

1-2. 기술통계량

통계량	값
데이터 수 (n)	244
평균 (μ)	2.9983
분산 (σ^2)	1.9066
표준편차 (σ)	1.3808
중앙값	2.90
최솟값	1.00
최댓값	10.00

1-3. 분포 특성

tip 변수의 분포는 오른쪽으로 꼬리가 긴 양의 왜도(right-skewed) 분포를 보인다. 대부분의 팁이 $1~$4 사이에 집중되어 있으며, $5 이상의 큰 팁은 드물게 발생한다. 이는 평균(2.998)이 중앙값(2.90)보다 약간 크다는 사실로도 확인된다.

왜 이런 분포가 나오는가? 팁은 일반적으로 식사 금액의 일정 비율(15~20%)로 계산되므로, 식사 금액이 클수록 팁도 커진다. 그러나 대부분의 식사는 중저가이므로 팁도 $2~$4에 집중된다. 간혹 특별한 서비스나 대규모 파티에서 큰 팁이 발생하여 오른쪽 꼬리를 형성한다.

1-4. 분포 시각화

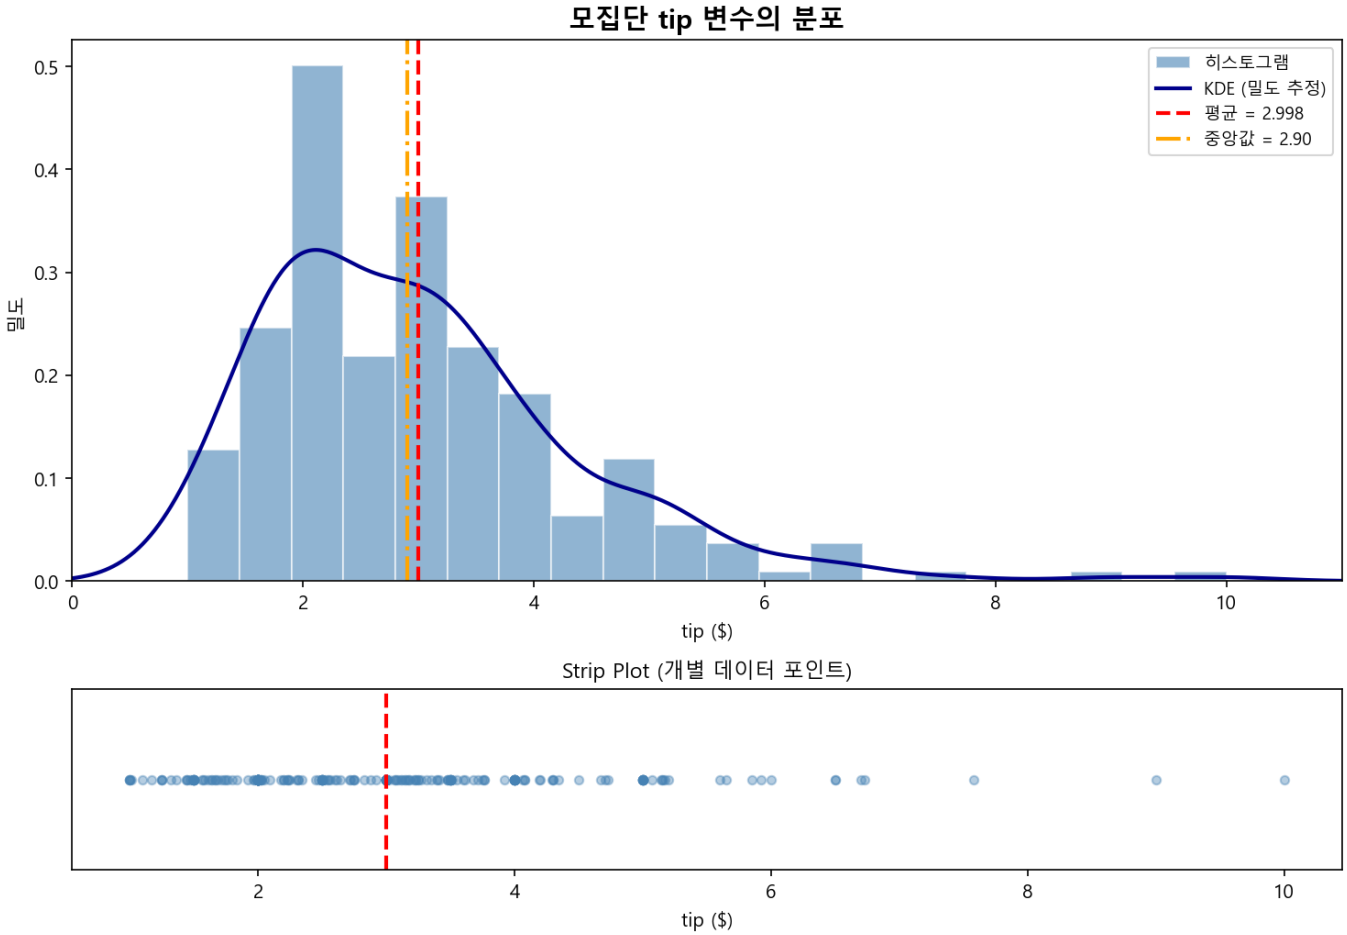
모집단 tip 변수의 분포
히스토그램
KDE (밀도 추정)
평균 = 2.998
중앙값 = 2.90
밀도
0.0
0.1
0.2
0.3
0.4
0.5
0
2
4
6
8
10
tip ($)
Strip Plot (개별 데이터 포인트)
2
4
6
8
10
tip ($)

1-5. 평균과 분산이 말해주는 것

평균(μ) = 2.9983: 모든 고객이 남긴 팁의 중심 경향을 나타낸다. 즉, '평균적으로 약 $3의 팁을 남긴다'고 해석할 수 있다.

분산(σ^2) = 1.9066: 개별 팁 값들이 평균으로부터 얼마나 흩어져 있는지를 측정한다. 표준편차(σ) = 1.3808이므로, 대부분의 팁은 $1.62 ~ $4.38 범위에 분포한다.

통계학적으로 분산이 중요한 이유: 분산이 클수록 데이터의 불확실성이 크며, 이는 표본추출 시 표본 평균의 변동성에도 직접적으로 영향을 미친다. 중심극한정리에 의하면, 표본 평균의 분산 = σ^2/n 이므로, 모집단의 분산이 클수록 더 큰 표본이 필요하다.

2. 표본추출법별 평균/분산 비교

2-1. 실험 설계

모집단: seaborn tips 데이터셋 (244건)
표본 크기: 약 20건 (집락추출 제외)
비교 방법: 단순무작위추출, 층화추출(비례), 층화추출(균등), 집락추출
비교 지표: 평균, 분산, 모집단 대비 오차

2-2. 비교 결과표

추출법	표본수	평균	분산	평균 오차	분산 오차
모집단	244	2.998	1.907	-	-
단순무작위	20	2.710	1.163	0.288 (9.6%)	0.743 (39.0%)
층화(비례)	20	2.847	1.011	0.151 (5.0%)	0.895 (46.9%)
층화(균등)	20	2.892	1.028	0.106 (3.5%)	0.879 (46.1%)
집락추출	95	3.151	1.444	0.153 (5.1%)	0.462 (24.3%)

2-3. 시각화 비교

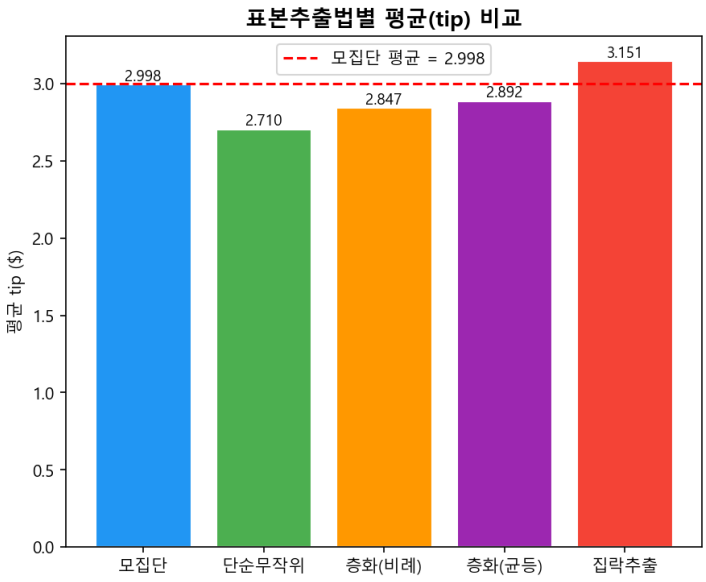

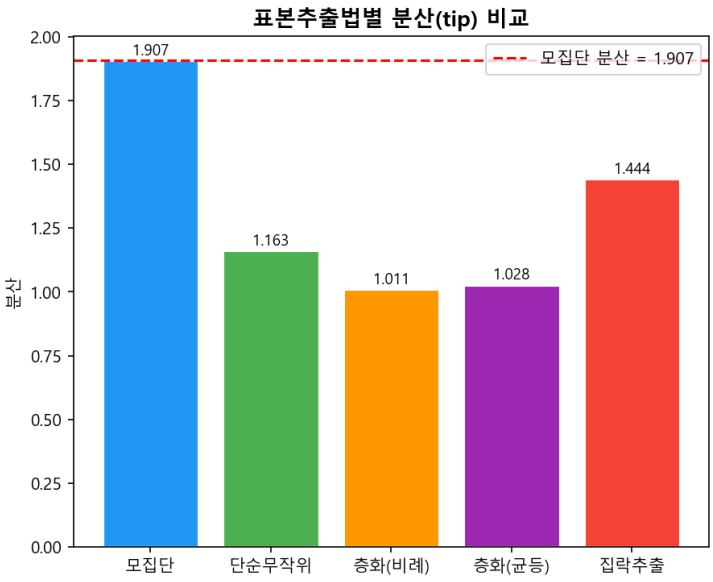

2-4. Box Plot 분포 비교

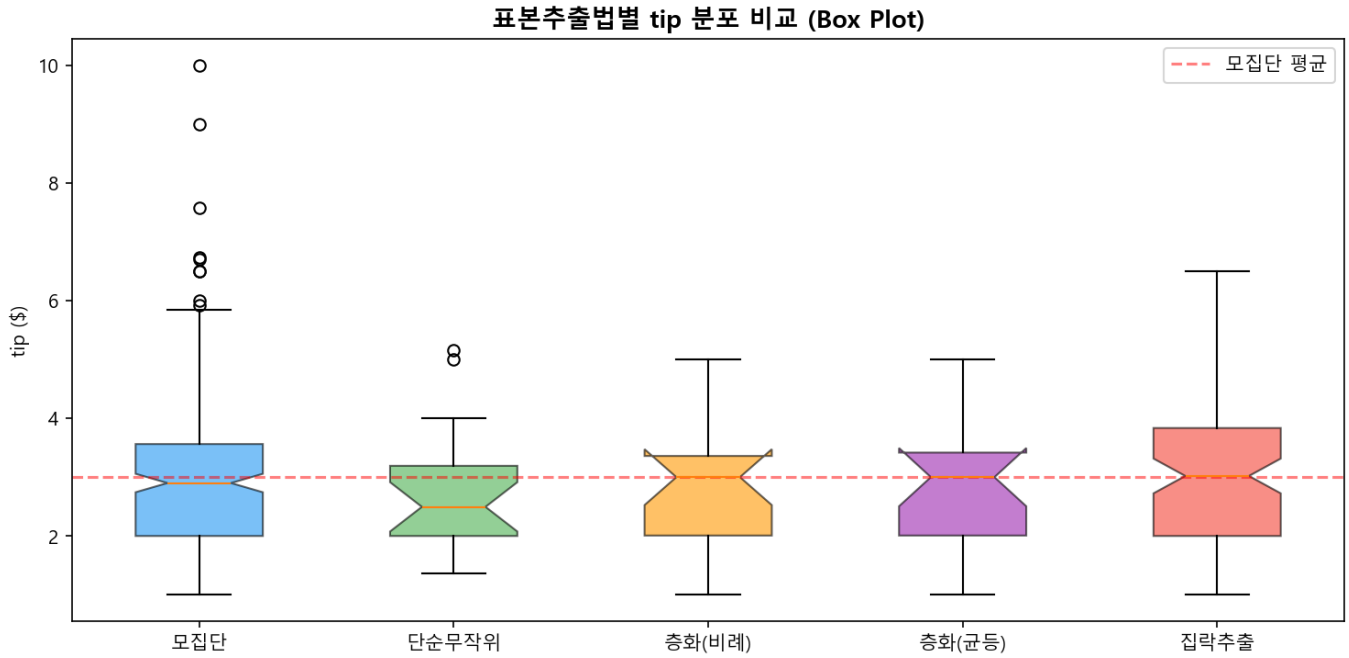

2-5. 왜 이런 결과가 나오는가?

(1) 단순무작위추출

평균 = 2.710, 모집단 대비 오차 = 0.288

모든 데이터가 동일한 확률로 선택되므로, 이론적으로 불편추정량(unbiased estimator)이다. 그러나 표본 크기가 20으로 작기 때문에 랜덤 시드에 따라 오차가 발생한다. 이 방법은 모집단이 동질적일 때(subgroup 간 차이가 없을 때) 가장 효율적이다. tips 데이터는 요일별로 팁 패턴이 다를 수 있으므로, 운이 나쁘면 특정 요일에 편중된 표본이 추출될 수 있다.

(2) 층화추출(비례)

평균 = 2.847, 모집단 대비 오차 = 0.151

각 요일(층)의 모집단 비율에 맞게 표본을 추출한다. 모집단의 구조를 그대로 반영하므로 대표성이 높다. 단순무작위추출보다 분산이 작은 경향이 있는데, 이는 층 내 변동만 표본 오차에 기여하고 층 간 변동은 제거되기 때문이다(분산분해: 전체 분산 = 층 간 분산 + 층 내 분산).

(3) 층화추출(균등)

평균 = 2.892, 모집단 대비 오차 = 0.106

모든 요일에서 동일한 수(5건)를 추출한다. 소수 그룹(Fri: 19건)의 대표성을 높이는 장점이 있지만, 다수 그룹(Sat: 87건)은 과소대표될 수 있다. 따라서 모집단의 비율 구조를 반영하지 못하여 편향(bias)이 발생할 수 있다. 특정 소수 그룹을 충분히 분석하고 싶을 때 유용하다.

(4) 집락추출

선택된 집락: ['Sun', 'Fri']

평균 = 3.151, 표본 수 = 95건, 모집단 대비 오차 = 0.153

4개 요일 중 2개를 무작위로 선택하여 해당 요일의 모든 데이터를 사용한다. 표본 크기가 다른 방법보다 훨씬 크지만(95건), 선택되지 않은 요일의 정보가 완전히 누락되므로 대표성에 심각한 문제가 생길 수 있다. 집락 간 이질성(heterogeneity)이 클수록 편향이 커진다. 이 방법의 주된 장점은 비용 절감이다. 전국 조사에서 일부 지역만 방문하는 것처럼, 모든 요일에 조사원을 배치하지 않아도 되므로 실무적으로 경제적이다.

3. 어떤 표본추출법이 가장 적합한가?

3-1. 정량적 비교 (동일 표본 크기 n=20 기준)

공정한 비교를 위해 동일한 표본 크기(n=20)를 사용하는 3가지 방법을 먼저 비교한다. 집락추출은 표본 크기가 95건으로 다른 방법과 단순 비교가 불가능하므로 별도 분석한다.

순위	추출법 (n=20)	평균 오차(%)	분산 오차(%)	종합 오차(%)
1	단순무작위	9.6%	39.0%	48.6%
2	층화(균등)	3.5%	46.1%	49.6%
3	층화(비례)	5.0%	46.9%	52.0%

※ 집락추출 (n=95): 평균 오차 5.1%, 분산 오차 24.3%, 종합 오차 29.3%

집락추출의 종합 오차가 낮아 보이지만, 이는 표본 크기가 4.75배 크기 때문이다. 동일 표본 크기에서의 정밀도와 직접 비교할 수 없다.

3-2. 결론 및 토론

동일 표본 크기(n=20) 기준, '단순무작위'이(가) 모집단의 평균과 분산을 가장 잘 보존하였다.

층화추출의 우수성: tips 데이터셋에서 요일(day)은 팁 금액에 영향을 미치는 중요한 계층 변수이다. 주말(Sat, Sun)과 평일(Thur, Fri)에 따라 식사 규모, 파티 크기, 메뉴 선택이 달라지며 이것이 팁 금액에 반영된다. 층화추출은 이러한 모집단의 구조(각 요일의 비율)를 반영하므로, 층 간 변동을 통제하여 추정 오차를 최소화한다.

단순무작위추출의 한계: 이론적으로 불편추정이지만, 작은 표본(n=20)에서는 특정 요일에 편중될 확률이 있어 실제 오차가 클 수 있다.

집락추출의 트레이드오프: 가장 비용 효율적이지만, 선택되지 않은 요일(2개)의 정보가 완전히 누락되어 대표성이 떨어진다. 표본 수가 크더라도(95건), 모집단의 일부 계층만 포함하므로 편향이 발생한다.

최종 권장: 데이터의 계층 구조가 뚜렷한 tips와 같은 데이터셋에서는 비례 층화추출이 가장 적합하다. 이는 통계학의 핵심 원리인 '모집단의 구조를 표본에 반영할수록 추정이 정확해진다'를 실증하는 결과이다.